

Reduction de dimension avec l'Analyse en Composante Principal

BADJO Dibé

Exploration de données

```
library(tidyverse)
```

```
-- Attaching packages ----- tidyverse 1.3.2 --
v ggplot2 3.4.1      v purrr   1.0.1
v tibble  3.1.8      v dplyr  1.1.0
v tidyr   1.3.0      v stringr 1.5.0
v readr   2.1.4      v forcats 1.0.0
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
```

```
library(FactoMineR)
library(factoextra)
```

Welcome! Want to learn more? See two factoextra-related books at <https://goo.gl/ve3WBa>

Rows: 8 Columns: 11

```
-- Column specification -----
Delimiter: ","
chr  (1): type
dbl (10): M1, M2, M3, M4, M5, M6, M7, M8, M9, M10
```

i Use `spec()` to retrieve the full column specification for this data.

i Specify the column types or set `show_col_types = FALSE` to quiet this message.

```
head(data)
```


```
# A tibble: 6 x 11
```

	type	M1	M2	M3	M4	M5	M6	M7	M8	M9	M10
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	Cancer1	22.9	69.5	73.8	2.69	82.1	1.1	1.19	4.24	5.23	3.64
2	Cancer2	17.6	65.0	79.7	51.4	49.4	22.1	7.31	6.15	1.03	9.23
3	Cancer3	23.5	70.7	78.5	39.7	71.1	16.8	9.03	8.92	2.90	13.0
4	Cancer4	9.29	73.4	77.9	86.9	14.9	6.23	37.6	17.5	8.13	8.88
5	Cancer5	39.2	61.6	65.4	55.4	39.7	7.71	34.4	22.3	8.42	29.4
6	Cancer6	69.1	46.6	36.6	40.9	20.9	32.1	66.6	44.6	23.5	57.4

```
x <- data[1:7,-1]
```

```
summar <- summary(x)  
view(summar)
```


```
boxplot(x)
```



```
matCors <- cor(x)  
view(matCors)
```

```
Xsc <- scale(x, scale = T)
```

```
boxplot(Xsc)
```



Pour parvenir à trouver les composantes principales, il faut tout d'abord calculer la matrice $\text{transpose}(X) \cdot X$

```
sigma <- t(Xsc) %*% Xsc/nrow(Xsc)
view(sigma)
```

Utilisons cette matrice pour calculer ensuite les valeurs propres et les vecteurs propres

```
ACP <- eigen(sigma)
```

```
class(ACP)
```

```
[1] "eigen"
```

Les valeurs propres

```
values <- ACP$values
values
```

```
[1] 5.899224e+00 1.661563e+00 5.142035e-01 3.981676e-01 8.649222e-02
[6] 1.177830e-02 3.683852e-16 1.068940e-16 -4.803234e-17 -8.293099e-17
```

Les vecteurs propres

```
vec <- ACP$vectors
```

```
view(vec)
```

Pour savoir le nombre de vecteur propre a selection il faut tracer le graph suivant, appelé le graph de coude, dans les resultats, le nombre de composante principale a sélectionner est 2

```
inertie <- cumsum(values)/sum(values)
inertie
```

```
[1] 0.6882428 0.8820918 0.9420822 0.9885351 0.9986259 1.0000000 1.0000000
[8] 1.0000000 1.0000000 1.0000000
```

Une autre manière de le savoir est de voir combien de vecteur propre garde plus de 80% de l'information, dans les resultats, les deux premiers vecteur propres garde plus de 80% de l'information ce qui vient confirmé le nombre qu'on a selectionner qui est 2


```
pourcinertie <- inertie*100
pourcinertie
```

```
[1] 68.82428 88.20918 94.20822 98.85351 99.86259 100.00000 100.00000
[8] 100.00000 100.00000 100.00000
```

Plus de 80% de la variance sont expliquer par les 2 premiers composant principales, ce qui nous conduit a garder que ces deux composantes.

Dans le pourcentage expliquer par ces deux composant, le premier composant á lui seul explique approximativement 68% de la variance

```
plot(vec[, 1:2], pch = 2, cex = values)
text(vec[, 1:2], labels = rownames(vec), pos = 3)
```




```
res.acp<-PCA(x, graph = FALSE)
```

```
view(res.acp$var$cos2)
```


```
get_eigenvalue(res.acp)
```

	eigenvalue	variance.percent	cumulative.variance.percent
Dim.1	6.88242795	68.8242795	68.82428
Dim.2	1.93849019	19.3849019	88.20918
Dim.3	0.59990407	5.9990407	94.20822
Dim.4	0.46452885	4.6452885	98.85351
Dim.5	0.10090758	1.0090758	99.86259
Dim.6	0.01374135	0.1374135	100.00000


```
fviz_eig(res.acp)
```



```
fviz_pca_ind(res.acp)
```



```
fviz_pca_var(res.acp)
```



```
fviz_pca_biplot(res.acp)
```

